

# 2026 《人工智能导论》大作业

任务名称： 可解释谣言检测系统

完成组号： 14

小组人员： 张子腾、王麒鸿、胡宁一、陈书展

完成时间： 2026.06.20

## 1. 任务目标

构建可解释的谣言检测模型，对英文推文二分类（0=非谣言，1=谣言），同时输出自然语言解释，需具备跨事件泛化能力。

## 2. 具体内容

### 2.1 系统架构

系统采用分类器 + 解释生成器两阶段解耦架构：



分类阶段：以 `cardiffnlp/twitter-roberta-base` 为基座，LoRA 进行参数高效微调，输出二分类标签及置信度。模型仅使用推文文本——这是本设计的关键决策：若将 `event` 作为特征，模型可能学习“某事件=谣言”的捷径，在新事件上完全失效。针对数据集类别不均衡问题，采用 `Focal Loss` ( $\gamma=2.0$ ) 替代标准交叉熵损失，迫使模型聚焦于难分类样本。训练采用 LOEO 交叉验证（每次留一个完整事件做验证），以模拟新事件的真实泛化场景。

解释阶段：对分类器的梯度进行 `Gradient×Input` 归因，提取 top-6 关键词作为锚点，拼接标签和置信度后调用 DeepSeek V3.2 (SJTU API) 生成 2-3 句自然语言解释。API 不可用时自动降级为模板输出。

性能参数：模型约 125M 参数（LoRA 约 1.2M），单条推理约 15ms，解释生成约 2 秒/条。

### 2.2 核心代码

共 13 个源文件。`model.py`：LoRA 分类 + FocalLoss；`train_loeo.py`：LOEO + 早停；`llm_explain.py`：批量 LLM 调用与 fallback；`explain_tokens.py`：Gradient×Input 关键词提取；`preprocess.py`：文本规范化。支持 `--model-name` 灵活切换基模。

### 2.3 检测结果

LOEO 跨事件泛化：7 轮平均 Acc=68.89%，Macro F1=0.5814。均衡事件（Event 4/5/6，谣言占比 43%–53%）F1 在 0.69–0.73；极端事件 Event 3（99%谣言，仅 2 条非谣言）Acc 仅 29.63%，该事件文本高度同质且模型几乎无法学习非谣言特征；Event 2（全谣言，9 条）Acc=88.89% 但 Macro F1 无意义。详细轮次指标见下表：

| 轮次 | 验证事件（谣言占比） | 样本数 | Acc    | Macro F1 |
|----|------------|-----|--------|----------|
| 1  | 0（20%）     | 66  | 0.7424 | 0.5187   |
| 2  | 1（25%）     | 799 | 0.7635 | 0.6132   |
| 3  | 2（100%）    | 9   | 0.8889 | —        |
| 4  | 3（99%）     | 162 | 0.2963 | 0.2346   |
| 5  | 4（51%）     | 327 | 0.6942 | 0.6910   |
| 6  | 5（43%）     | 854 | 0.7272 | 0.7269   |
| 7  | 6（53%）     | 623 | 0.7095 | 0.7041   |

注：Event 2/3 因类别极端不均衡，Macro F1 无统计意义。

LOEO 与全量模型（val.csv Acc=88.03%）差距约 19 个百分点，原因是 val.csv 事件与训练集重叠，LOEO 完全隔离验证事件，更真实反映泛化。

全量模型（Focal Loss  $\gamma=2.0$ ，val.csv 401 条）：

| Acc    | Macro F1 | F1(非谣言/谣言)      | AUC    |
|--------|----------|-----------------|--------|
| 88.03% | 0.8789   | 0.8919 / 0.8659 | 0.9391 |

共 48 个错误（CE Loss 基线 53 个）。各事件 Acc：Event 0：89.7%，1：87.2%，2：100%(1条)，3：100%，4：82.6%，5：86.0%，6：91.0%。

### 2.4 判断依据

Gradient×Input 提取 top-6 关键词作为锚点，LLM 生成 2-3 句解释。Prompt 强制引用原文、按置信度分层（低置信度识别混合信号）。优化后前缀问题从约 20% 降至 0%，引用短语 2.72 个/条。


典型示例：

- 谣言：“BREAKING NEWS” creates false urgency without verification, “identified as Michael Joseph Hall” presents unconfirmed identity as fact.
- 非谣言（低置信度）：Cites “a Sandy Hook Dad and ex-cop” and “Respectfully” tone, but “our towns murders” is emotionally charged without attribution — mixed signals.

解释质量量化：引用短语 2.72 个/条，句子数 2.19 句，前缀问题 0/401，fallback 率 0%。

## 2.5 消融实验与设计依据

为说明基模和训练策略的选择，我们补充一组消融对比。指标均为公开 `val.csv` 上的 Accuracy，重点比较“弱基模、当前基模全参微调、当前基模 LoRA、当前基模 LoRA + Focal Loss”四种设置。



从结果看，弱基模即使同样使用 LoRA，Accuracy 仍低于当前 Twitter-RoBERTa 基模，说明社交媒体语料预训练与推文谣言检测任务更匹配。当前基模下，全参微调和 LoRA 在默认设置中基本持平；考虑 checkpoint 体积、训练稳定性和复现成本，LoRA 更适合作为最终系统的主线。在 LoRA 基础上加入 Focal Loss 后，模型更关注类别不均衡下的难样本，Accuracy 提升到 88.03%，因此最终采用 Twitter-RoBERTa + LoRA + Focal Loss。

## 3. 工作总结

---

### 3.1 收获与心得

(1) 评估方式的选择直接影响对模型能力的判断。全量模型在 `val.csv` 上的 F1 可以到 0.87 左右，但 LOEO 平均 F1 只有 0.58。如果只看普通验证集，很容易把事件重叠带来的优势误认为模型真的学会了泛化。这个结果也提醒我们，类似任务最好优先做事件隔离评估。

(2) 领域知识和损失函数设计同等重要。面向 Twitter 语料预训练的 RoBERTa 比弱基模更稳，模型和数据域是否匹配很重要；Focal Loss 又进一步减少了错误数，类别不均衡不能只靠模型自己消化。解释部分也类似：同一个 LLM，prompt 中是否要求引用原文、是否区分置信度，会直接影响解释是不是具体。

### 3.2 挑战与解决方案

- 极端类别不均衡：Event 3 只有 2 条非谣言样本，模型很难学到稳定的反例特征。我们对少数类样本做 WordNet 同义词替换增强，并在训练中加入 `balanced class weight`。
- API 速率限制：SJTU API 限速 10 次/分钟，逐条调用 401 条大约需要 40 分钟。后来改成每 5 条推文合并为一次请求，总耗时降到约 13 分钟。

---

## 4. 课程建议

---

建议作业说明中提前明确最终测试数据格式，尤其是是否包含 `event` 字段；同时也可以提前说明 API 的速率限制，方便大家在设计阶段就规划好批量推理方案；

---

## 成员分工

| 成员  | 职责                                | 主要文件                                                                 |
|-----|-----------------------------------|----------------------------------------------------------------------|
| 张子腾 | 项目统筹、模型实现、Focal Loss 优化、数据增强、最终整合 | model.py, train_loeo.py, train_final.py, dataset.py, data_augment.py |
| 胡宁一 | 配合模型选型与实验设计、基础模型优化、数据预处理、系统集成     | preprocess.py, main.py, batch_pipeline.py, predict_batch.py          |
| 王麒鸿 | 参与总体方案设计、可解释性归因、LLM 解释生成          | explain_tokens.py, llm_explain.py                                    |
| 陈书展 | 承担技术路线讨论、评测分析、解释质量评估、报告与文档        | evaluate.py, eval_explanations.py, README.md, report.pdf             |